

Relatório de Revisão Técnica YOLOv8 para Detecção de Sujeira

Disciplina: Inteligência Artificial (FGA0221)

Professor: Fabiano Araujo Soares, Dr


Aluno: Marcos Antonio Teles de Castilhos

Contexto do Projeto:

Este relatório técnico aborda a avaliação de um modelo de Detecção de Objetos baseado na arquitetura **YOLOv8n (nano)**, que foi treinado por meio de Aprendizado Supervisionado (Deep Learning) e *Transfer Learning*. O objetivo primário é dotar um agente (robô aspirador) de visão computacional capaz de classificar quatro categorias de sujeira (*dirt*, *liquid*, *marks*, *trash*), uma aplicação fundamental para a automação inteligente. O treinamento foi limitado a **10 épocas**, o que serve como um teste inicial, mas é insuficiente para a convergência ideal.

1. Desempenho Geral de Treinamento e Convergência

A análise das curvas de perda e métricas de desempenho indica que o modelo YOLOv8n demonstrou uma curva de aprendizado positiva durante as 10 épocas de treinamento.




As curvas de perda, incluindo **box_loss** (relacionada à precisão das caixas delimitadoras) e **cls_loss** (relacionada à precisão da classificação), tanto para o conjunto de treinamento quanto para o de validação, exibiram uma **tendência decrescente contínua**. Isso é um forte indício de que o modelo estava aprendendo e ajustando seus pesos de forma eficaz.

No entanto, dado que tanto as perdas quanto as métricas de precisão e *recall* continuam a melhorar (subir) até a última época registrada, o modelo **não atingiu a convergência total**. A continuação do treinamento (aumento do número de épocas) é sugerida para maximizar a generalização do modelo e estabilizar as métricas.

As métricas finais de desempenho global, medidas com um limite de *Intersection over Union* (IoU) de 0.5, mostram um **mAP50 (Precisão Média) de 0.720**, com *Precision* média de 0.7630 e *Recall* de 0.6900.

2. Análise de Erros (Matriz de Confusão)

A matriz de confusão normalizada (colunas = valores verdadeiros, linhas = valores preditos) revela uma performance altamente variável entre as classes, expondo pontos críticos para a operação do robô:



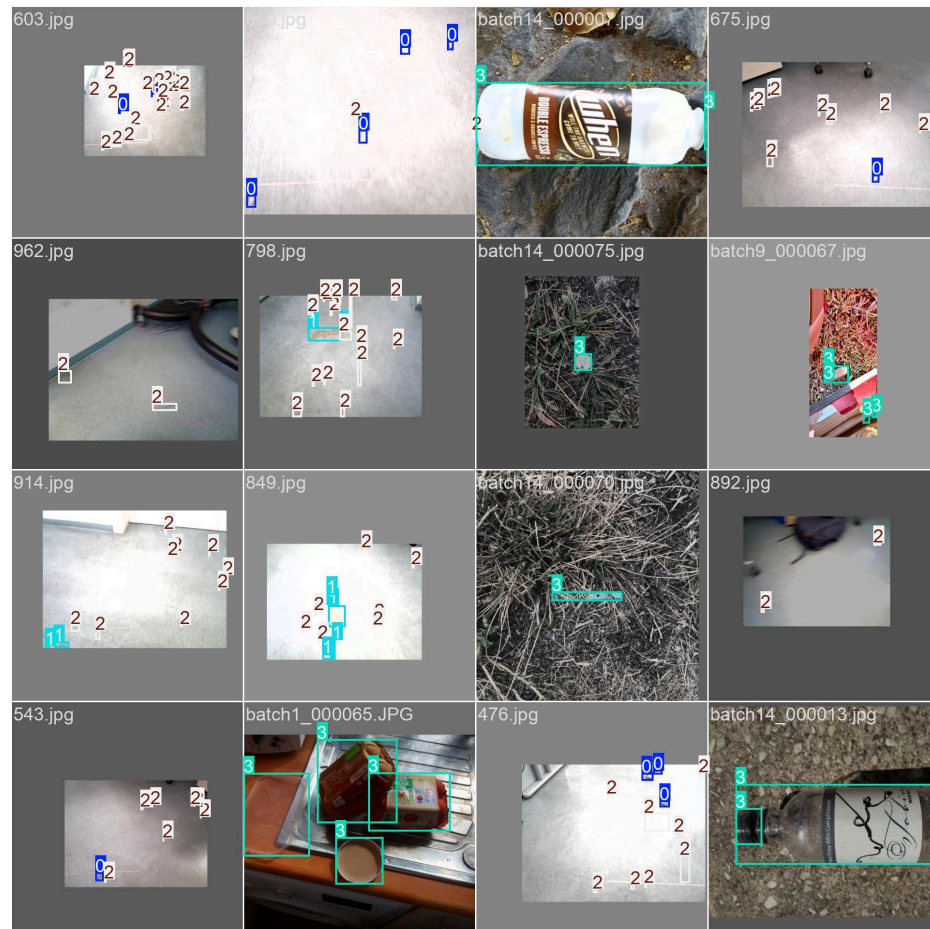
1. Classes de Alto Desempenho (Alta Diagonal):

- A classe **dirt** apresenta um desempenho robusto, com **97%** de acertos, e a classe **liquid** demonstra alta confiabilidade com **76%** de acertos. Estas classes, essenciais para um robô aspirador, são bem distinguidas.

2. Classes Críticas (Alta Confusão):

- A maior falha reside na classificação de instâncias *True* (Verdadeiras) de **trash** (lixo) e **marks** (marcas).
- Para a classe **trash**, 69% das instâncias verdadeiras foram erroneamente classificadas como **background (fundo)**. Este é um **elevado índice de Falsos Negativos (FN)**, significando que o robô **deixará de detectar a maior parte do lixo** presente no chão, comprometendo a eficácia da limpeza.

- A classe **marks** também exibe confusão significativa, sendo 50% das instâncias verdadeiras classificadas como **background**.




O impacto operacional desta confusão é severo: o robô apresenta um **viés de classificação** em que *trash* e *marks* são frequentemente tratados como ausentes, falhando em sua missão principal de detecção de sujeira.

3. Compromisso Precisão vs. Recall (F1-Score)



A análise das curvas de *Precision-Recall* (PR Curve) e *F1-Confidence* é crucial para determinar o equilíbrio entre encontrar todas as sujeiras (Recall) e garantir que as detecções sejam corretas (Precision).

1. **Desempenho por Classe (mAP@0.5):** O desempenho é desigual, o que é confirmado pela curva PR. As classes *dirt* (0.989) e *liquid* (0.858) dominam, enquanto *marks* (0.692) e, notavelmente, *trash* (0.341) apresentam baixo desempenho. O **baixo mAP** para *trash* é o principal fator limitante da performance geral.




2. **Compromisso Geral:** A curva de *Recall-Confidence* mostra que, para alcançar um *Recall* geral aceitável (por exemplo, 0.84), o modelo precisa aceitar uma confiança mínima de **0.000**, o que inevitavelmente geraria um volume excessivo de Falsos Positivos (*Precision* muito baixa). Por outro lado,

a curva de *Precision-Confidence* indica que para garantir 100% de *Precision* (zero Falso Positivo), a confiança deve ser ajustada para **0.898** ou mais.



3. **F1-Score (Ponto de Equilíbrio):** O ponto de equilíbrio para todas as classes, maximizando o F1-Score (0.71), é alcançado com um limiar de confiança de **0.229**. Este limiar baixo confirma que o modelo precisa ser "permissivo" para equilibrar a detecção (Recall) e a precisão, especialmente devido ao

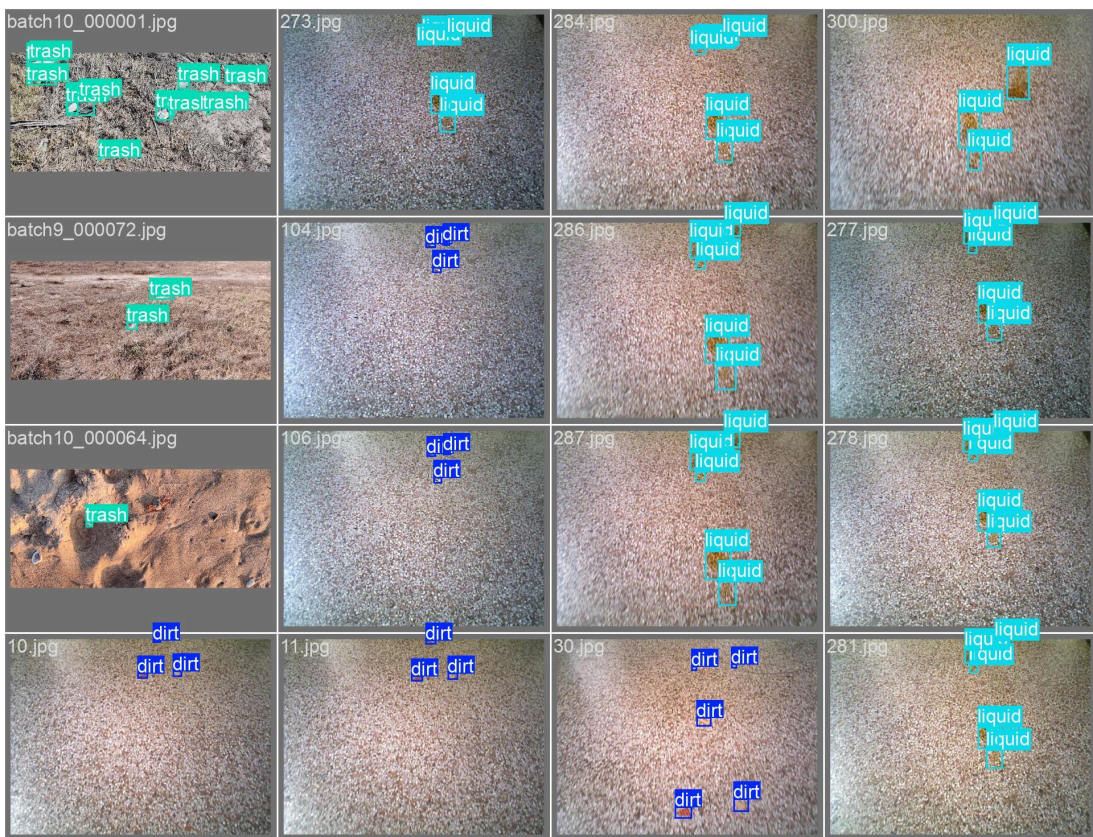
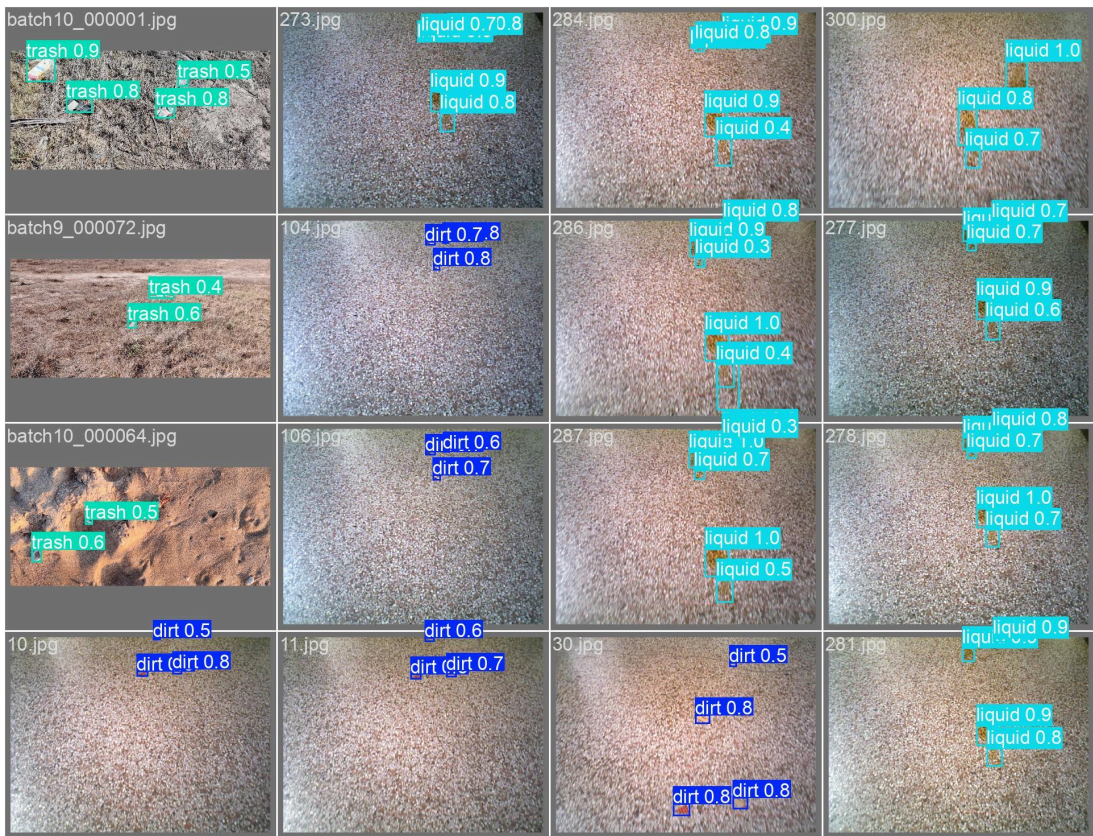
desempenho ruim da classe *trash*.



4. Validação Visual e Qualidade das Caixas Delimitadoras

A inspeção das predições de validação (`val_batch_pred`) demonstra que o modelo, quando acerta a classificação, geralmente gera **caixas delimitadoras (*bounding boxes*) bem ajustadas** aos objetos,. O uso da arquitetura Deep Learning YOLOv8n é eficaz na localização espacial dos objetos, e o modelo consegue detectar **objetos pequenos** (por exemplo, detecções de *dirt* com confiança 0.8 no lote 0).

No entanto, a validação visual também reitera o problema de generalização e os Falsos Negativos: em alguns casos, onde os rótulos mostram múltiplas instâncias pequenas de *trash* ou *dirt*, o modelo prediz menos caixas ou as agrupa com menor confiança. A variância dos dados, como a iluminação e o tipo de superfície, ainda representa um desafio para a **generalização** da rede.




Conclusão: Viabilidade de Implantação

A aplicação da arquitetura Deep Learning YOLOv8n via *Transfer Learning* é tecnicamente sólida e apropriada para a tarefa de Detecção de Sujeira em tempo real,. O modelo provou ter alta capacidade de extrair *features* complexas e demonstrou excelente desempenho de classificação para *dirt* e *liquid*.

Contudo, a viabilidade de implantação em um robô aspirador real é **limitada e arriscada** com os resultados atuais. O alto índice de **Falsos Negativos** (FN) na classe *trash* (69% de erro, classificado como *background*) e *marks* (50% de erro, classificado como *background*) significa que o robô **falhará em detectar a maior parte do lixo sólido e das marcas de sujeira**, exigindo intervenção humana constante.

Para que este modelo seja viável, é imperativo:

1. **Retreinamento Estendido:** Aumentar o número de épocas para permitir a convergência completa.
2. **Balanceamento de Dados e Aumento:** Focar em técnicas de reamostragem ou aumento de dados (data augmentation) nas classes minoritárias (*liquid* e *trash*) para melhorar sua representação e reduzir o viés de classificação.



Em resumo, embora a base do modelo seja promissora, sua capacidade de **generalização** para detectar lixo e marcas é atualmente insuficiente, exigindo a mitigação urgente dos Falsos Negativos críticos antes da implementação em campo,.